

Introducción al PLN

- **PLN:** Rama de la inteligencia artificial que se centra en la **interacción entre computadoras y el lenguaje humano**.
- Importancia del PLN: Facilita la comunicación hombre-máquina, análisis de datos textuales y comprensión de información.
- Historia del PLN: Desde el análisis de sintaxis hasta el uso de redes neuronales y modelos de lenguaje avanzados.
 - Aplicaciones del PLN: Chatbots, traducción automática, análisis de sentimientos, motores de búsqueda.



Lenguaje escrito

- Internet y la producción de datos digitales han revolucionado el flujo de la información, otra vez.

- Existe demasiada información para procesar, por suerte tenemos la IA para buscar, analizar, clasificar, recuperar, sintetizar, y interpretar (entender)
- IA puede **imitar las intuiciones humanas** para entender significados (de qué trata un texto, ej.: corrupción)
- IA puede **detectar patrones**, que quizás a los humanos les cueste mucho (ej.: estilo de un autor particular de un set de textos sin nombres)

Borges o
Cortázar?

"Siempre imaginé que el paraíso sería algún tipo de biblioteca."

"Hay derrotas que tienen más dignidad que una victoria."



¿Qué es PLN?

- **Habilidad** de un programa de computadora para **interpretar el lenguaje humano**, tanto hablado como escrito, también llamado *lenguaje natural*.

- Uno de sus fines principales es mejorar la interacción humano-computadora (en inglés, HCI).
- Los humanos tenemos diferentes sensores (los oídos, los ojos, etc.), de forma similar las computadoras también los poseen (micrófono, cámaras, etc.) y el PLN procesa la información por medio de la IA y le da un sentido que la computadora puede interpretar.

¿Qué es PLN?

- Pertenece al campo de la Lingüística Computacional
 - Natural Language Understanding (NLU),
 - Natural Language Generation (NLG): STT y TTS



- Se inició en 1950 con la publicación "Computing machinery and intelligence" (A. Turing)

I am going to Beijing tomorrow. 我明天要去北京。


I go swimming at school every morning at 7am.
我每天早上7点去学校游泳。

I am going shopping with my friends at Central on Sunday.
我和我的朋友星期天要去中环买东西。

<https://academic.oup.com/mind/article/LIX/236/433/986238>

- Es un tema de actualidad porque el problema siempre se puede complejizar más...
Dificultades: ambigüedad de las lenguas,
recepción imperfecta de los datos,
separación entre palabras, entre otros.

¿Qué es PLN?



¿Qué hacemos con PLN en texto?

- Inicios 1950s. Alan Turing
 - 1950s-1990s. PLN ampliamente **basado en reglas**, desarrolladas por lingüistas para determinar cómo las máquinas podían procesar lenguajes.
 - 1990s. Las computadoras se vuelven más rápidas y se usan para desarrollar reglas basadas en **estadísticas lingüísticas** sin que un lingüista creara todas las reglas. Entran al juego ingenieros y científicos de datos.
 - 2000-. PLN experimentó un crecimiento exponencial en popularidad científica y de consumidores. Hoy en día, implican una combinación de lingüística clásica, métodos estadísticos, **inteligencia artificial** y un gran poder de cómputo.

Applications of Natural Language Processing



Tareas del PLN

Reconocimiento de Entidades Nombradas (NER)

- Identifica y clasifica entidades importantes en el texto, como nombres de personas, lugares, organizaciones, etc.
- Utilizado en: extracción de información, análisis de noticias, blogs, etc.

Tareas del PLN

Extracción de Información

- Identifica y estructura información específica a partir del texto (posiblemente no estructurado).
- Ejemplo: recuperación de respuestas en motores de búsqueda, análisis de opinión, documentos legales.

Partes del Contrato

Objeto y Duración del Contrato

Obligaciones y Compromisos

Cláusulas Importantes

Palabras clave:

<https://wordcount.com/es/keyword-extractor>

Tareas del PLN

Modelado de temas.

- Asignar etiquetas a los textos para agruparlos en categorías. Descubre temas latentes o dominantes en grandes volúmenes de texto.
- Utilizado en:
 - análisis de tendencias,
 - agrupación de documentos,
 - detección de comportamientos anómalos,
 - organización automática en disco,
 - envíos automatizados en organizaciones,
 - etc...

Tareas del PLN

Análisis de Sentimiento

Determina la actitud emocional detrás de un texto, como positiva, negativa o neutra.
Aplicaciones: análisis de opiniones en redes sociales, comentarios de clientes, etc.



Tareas más comunes del PLN

Generación de Lenguaje Natural

Produce texto coherente y gramaticalmente correcto de manera automática. Ejemplo: chatbots, generación de contenido automatizado.



Tareas del PLN

Resumen Automático

Crea resúmenes concisos de textos largos, preservando la información esencial.
Aplicaciones: resumen de artículos científicos, noticias, documentos legales.



Tareas más comunes del PLN

Traducción Automática

Transforma texto de un idioma a otro de manera automática.

Ejemplos: Google Translate, DeepL, Microsoft Translator, Amazon Translate,



chatGPT...

Tareas del PLN

Preguntas y Respuestas Automatizadas (QA)

Entiende preguntas formuladas en lenguaje natural y proporciona respuestas precisas.

Ejemplo: asistentes virtuales, sistemas de soporte al

Aplicaciones del PLN

- Cuidado de la salud (healthcare)
 - análisis y categorización de registros médicos
 - informes de registros automatizado
- Marketing inteligente
 - permite saber qué hacen los competidores y estar actualizados través del análisis de millones de blogs, sitios webs, etc.
 - análisis de comentarios de los clientes: analizar de las reseñas de las redes sociales
- Servicio al cliente por asistentes con ASR y TTS
 - comprender lo que dice el cliente y actuar en consecuencia
 - detectar emociones para evitar pérdida de clientes



Llama (Facebook), Claude (Anthropic)

- Un largo etc: LuzIA, POE, YouChat, PerplexityAI, CharacterAI, Aria, Socratic, GPT4All,

....

Herramientas más populares para el PLN

- **NLTK (Natural Language Toolkit)** - <https://www.nltk.org/>

- disponible para Windows, Mac OS X, and Linux
- es libre, de código abierto free, proyecto guiado por la comunidad
- libro “Natural Language Processing with Python” disponible en <https://www.nltk.org/book/>

- **SpaCy** - <https://spacy.io/>

- diseñada para aplicaciones en producción
- basada en modelos de aprendizaje profundo preentrenados, con soporte para múltiples idiomas
- documentación y guías disponibles en <https://spacy.io/usage>
- licencia MIT, con un enfoque en velocidad y eficiencia

proyecto abierto y colaborativo, ampliamente utilizado en investigación y aplicaciones industriales




- **The Apache OpenNLP library** - <https://opennlp.apache.org/>

- herramienta para NLP en texto, basadas en aprendizaje maquinal
- manual de uso disponible en [redacted]
- licencia Apache versión 2.0, proyecto colaborativo

- **Gensim** - <https://pypi.org/project/gensim/>

- librería de Python para modelado de tópicos, indexación de documentos, recuperación de



- similaridades en corpus enormes
- licencia LGPL-2

Técnicas clásicas del PLN

Fundamentos del Lenguaje Humano

- Fonología: estudio de los sonidos del habla.
- Morfología: estudio de la estructura y formación de las palabras.
- Sintaxis: reglas y principios que rigen la estructura de las oraciones.
- Semántica: significado de las palabras y las oraciones.
- Pragmática: uso del lenguaje en contextos específicos y cómo afecta la interpretación.

Fundamentos del Lenguaje Humano

- Fonología:
 - Fundamental para el ASR: reconocimiento automático del habla.
 - **Fonemas**: unidades mínimas de sonido del lenguaje, son 5 vocales y 19 consonantes en

español.



Fundamentos del Lenguaje Humano

- **Morfología:** Estudio de la estructura y formación de las palabras. ◦ Definición: La morfología es la rama de la lingüística que estudia la estructura y formación de las palabras.
 - **Morfemas:** Las **unidades mínimas** de significado en una lengua. Pueden ser raíces, prefijos o sufijos.

- Tipos de Morfemas: Morfemas libres (pueden aparecer solos, como "casa") y morfemas ligados (necesitan unirse a otros, como "re-" en "revisar").
- Procesamiento en PLN: En el PLN, la morfología ayuda a entender y generar palabras nuevas a partir de sus componentes básicos, crucial para la lematización y la radicalización.

Fundamentos del Lenguaje Humano

- Sintaxis: Reglas y principios que rigen la estructura de las oraciones. ○

Definición: La sintaxis es el estudio de las reglas y principios que gobiernan la [estructura de las oraciones](#).

- Orden de las Palabras: Diferentes lenguas tienen distintos órdenes de palabras.

Ejemplo: Sujeto-Verbo-Objeto (SVO) en inglés y español,
Sujeto-Objeto-Verbo (SOV) en japonés.

- PLN: análisis de dependencias, donde se identifican relaciones



gramaticales entre palabras.

Fundamentos del Lenguaje Humano


- Sintaxis: Reglas y principios que rigen la estructura de las oraciones. ○
Árboles Sintácticos: Representaciones gráficas de la estructura de una oración, mostrando relaciones jerárquicas entre las palabras.



Fundamentos del Lenguaje Humano

- Semántica: Significado de las palabras y las oraciones.
 - Definición: La semántica se centra en el [significado de las palabras y oraciones](#).
 - Relaciones Semánticas: Incluye sinónimos (palabras con significado similar), antónimos (significado opuesto), hiperónimos e hipónimos (categorías de una palabra general).
 - Desambiguación Semántica: El

proceso de resolver ambigüedades cuando una palabra tiene múltiples significados. Ejemplo: "banco" puede referirse a una institución financiera o a un asiento.



○ Impacto en crucial para y la

PLN: La comprensión semántica es tareas como la traducción automática generación de texto, donde el

significado preciso es fundamental.

Fundamentos del Lenguaje Humano

- Pragmática: Uso del lenguaje en contextos específicos y cómo afecta la interpretación.
 - Definición: La pragmática estudia el uso del [lenguaje en contextos específicos](#) y cómo afecta la interpretación.

- Contexto: Incluye el entorno, el conocimiento previo de los interlocutores y la intención detrás de las palabras.
- Actos de Habla: Acciones realizadas a través del lenguaje, como pedir, prometer, ordenar, etc. ○

Relevancia en PLN: La pragmática es esencial para desarrollar sistemas que entiendan la intención del usuario, más allá del significado literal de las palabras, como en chatbots y asistentes virtuales.

Tareas Clásicas del PLN:

Preprocesamiento

Técnicas de Preprocesamiento

- Normalización: es el proceso de transformar el texto a una forma estándar. ○

Pasos Comunes:

- Conversión de Siglas: Expandir siglas a su forma completa.
- Conversiones a Minúsculas: Convertir todo el texto a minúsculas para evitar duplicación de palabras debido a diferencias de mayúsculas y minúsculas.
- Expansión de Contracciones: Transformar contracciones a sus formas completas (e.g.,

"don't" a "do not").

- Normalización de Números: Convertir números a una forma estándar o eliminarlos si no son relevantes.

○ Ventajas: Mejora la consistencia y facilita el procesamiento y análisis posterior. ○

Aplicaciones en PLN: Clasificación de texto, análisis de sentimientos, y cualquier tarea que requiera datos consistentes.

Técnicas de Preprocesamiento

● Manejo de Emoticones

○ Traducción de Emoticones:

- Representaciones gráficas de emociones, estados de ánimo, y expresiones faciales. ■

La conversión a texto puede ayudar a los modelos a captar el tono y la intención del mensaje.

- Ejemplo: 😊 puede ser traducido a "feliz" o "sonriente", y 😞 a "triste".

○ Eliminación de Emoticones no Relevantes:

- En ciertos contextos, puede ser beneficioso eliminar los emoticones para simplificar el análisis del texto.
- Útil en el procesamiento de documentos formales o técnicos.

Técnicas de Preprocesamiento

- Limpieza de Texto

- Definición: la limpieza de texto implica eliminar o corregir elementos no deseados en el texto para preparar datos limpios y estructurados para el procesamiento.
 - Pasos comunes:
 - Eliminación de Puntuación: quitar signos de puntuación como comas, puntos y paréntesis.
 - Eliminación de Stop Words: quitar palabras comunes que no aportan mucho significado, como "y", "el", "a".
 - Corrección Ortográfica: arreglar errores tipográficos y ortográficos.
 - Eliminación de Espacios en Blanco: remover espacios en blanco adicionales.
 - Desafíos: Mantener el balance entre limpieza y pérdida de información relevante.
- Aplicaciones en PLN: Fundamental para mejorar la calidad de los datos antes de aplicar técnicas de análisis y modelado.

Ver sección “Pre-procesamiento” en Colab

Tareas Clásicas del PLN:

Procesamiento

Tareas Clásicas del PLN

- Tokenización
- Lematización y Radicalización
- Etiquetado de Partes del Discurso (POS tagging)
- Reconocimiento de Entidades Nombradas (NER)

Tareas Clásicas del PLN

- Tokenización: Dividir el texto en unidades más pequeñas como palabras o

frases.

- Definición: La tokenización es el proceso de dividir el texto en unidades más pequeñas, como palabras, frases o caracteres, llamados "tokens".
- Tipos de Tokenización:
 - Palabras: Separación basada en espacios y puntuación.
 - Frases: División en base a signos de puntuación mayores como puntos y comas. ■
 - Caracteres: Cada carácter individual es un token.
- Desafíos: Manejo de contracciones no preprocesadas (ej. "don't"), palabras compuestas (ej. "New York") y puntuación (ej. "U.S.A.").
- Aplicaciones en PLN: Es el primer paso en muchas tareas de PLN, como análisis de sentimientos y traducción automática, proporcionando unidades manejables para el procesamiento.

Ver sección "Tokenización" en Colab

Tareas Clásicas del PLN

- Lematización y Radicalización: Reducir las palabras a su forma base o raíz. ○
Definición:
 - Lematización: Convertir una palabra a su forma base o "lema" usando reglas lingüísticas

- (ej. "corriendo" a "correr").
- Radicalización: Reducir palabras a su raíz, a veces eliminando sufijos (ej. "running" a "run").
 - Diferencias: La lematización es más precisa ya que considera el contexto gramatical, mientras que la radicalización es más rápida pero menos exacta.
 - Ejemplos:
 - Lematización: "Mejores" a "Mejor".
 - Radicalización: "Jugando" a "Jug".
 - Aplicaciones en PLN: Ayuda en la normalización del texto, mejorando la precisión en tareas de búsqueda y análisis de texto.

Ver secciones “Lematización” y “Radicalización” en Colab

Tareas Clásicas del PLN

- Etiquetado de Partes del Discurso (POS tagging): Asignar categorías gramaticales a cada palabra.
 - Definición: El etiquetado de partes del discurso es el proceso de asignar categorías gramaticales a cada palabra en una oración, como sustantivo, verbo, adjetivo, etc. ○

Métodos:

- Basados en reglas: Utilización de reglas gramaticales predefinidas.
- Basados en aprendizaje automático: Modelos que aprenden de datos etiquetados. ○

Desafíos: Manejo de palabras polisémicas (ej. "banco" como sustantivo o verbo) y contextos ambiguos.

- Aplicaciones en PLN: Es fundamental para el análisis sintáctico, extracción de información y traducción automática, proporcionando información gramatical crítica.

Ver sección “Etiquetado de Partes del Discurso (POS)” en Colab

Tareas Clásicas del PLN

- Reconocimiento de Entidades Nombradas (NER): Identificar y clasificar entidades como nombres de personas, lugares, etc.
 - Definición: El reconocimiento de entidades nombradas (NER) es la tarea de identificar y clasificar nombres propios en un texto, como nombres de personas, lugares, organizaciones, fechas, etc.
 - Categorías Comunes: Personas, ubicaciones, organizaciones, fechas, cantidades, etc. ○

Desafíos: Ambigüedades (ej. "Apple" como empresa o fruta), y variaciones en nombres (ej. "NYC" vs. "New York City").

- Aplicaciones en PLN: Utilizado en motores de búsqueda, sistemas de recomendación, extracción de información y análisis de noticias, mejorando la comprensión y organización de la información.

Ver sección “Reconocimiento de entidades nombradas” en Colab

Técnicas de Preprocesamiento

- Tokenización Avanzada

- Técnicas Comunes:

- Subword Tokenization: Divide palabras en subunidades más pequeñas (e.g., Byte Pair Encoding, WordPiece) para manejar palabras desconocidas.
 - Tokenización Basada en Diccionario: Utiliza diccionarios específicos de lenguajes para una segmentación más precisa.
 - Tokenización Multilingüe: Adaptada para manejar textos en múltiples lenguajes.

Ventajas: Mejora la capacidad de manejar vocabularios grandes y palabras desconocidas. ○

Aplicaciones en PLN: Crucial para modelos de lenguaje modernos como BERT y GPT, que requieren una tokenización robusta y eficiente.

Desafíos en PLN

Desafíos en PLN

- Ambigüedades del lenguaje
- Variabilidades del lenguaje
- Problemas de datos en el entrenamiento de modelos

Desafíos en PLN

- Ambigüedad del Lenguaje
 - Ocurre cuando una palabra, frase o oración tiene múltiples significados.
 - Tipos de Ambigüedad:
 - Lexical: Una palabra tiene múltiples significados (e.g., "banco" puede referirse a una institución financiera o a un asiento).
 - Sintáctica: La estructura gramatical permite múltiples interpretaciones (e.g., "Vi al hombre

con los binoculares" puede significar que el hombre tiene los binoculares o que se usaron binoculares para ver al hombre).

- Semántica: La interpretación de una oración completa puede variar según el contexto (e.g., "Ella no vio el banco" puede significar que no vio el asiento o la institución financiera).
- Desafíos: Dificulta la desambiguación y comprensión precisa del texto por parte de los modelos de PLN.
- Soluciones: Uso de contextos más amplios, redes neuronales avanzadas y técnicas de desambiguación de palabras.

Desafíos en PLN

● Variabilidad del Lenguaje

- Diversidad en la forma en que se utiliza el lenguaje, incluyendo dialectos, jergas, y estilos de escritura.
- Ejemplos de Variabilidad:
 - Dialectos: Diferencias en el uso del idioma en diferentes regiones (e.g., español de España vs. español de México).

■ Jergas y Modismos: Términos y expresiones específicas de ciertos grupos o contextos. ■

Estilos de Escritura: Variaciones en la formalidad, tono y estructura del texto. ○ Desafíos: Los

modelos de PLN deben ser capaces de manejar esta diversidad para ser efectivos en diferentes contextos.

- Soluciones: Entrenamiento en conjuntos de datos diversos y técnicas de normalización de texto.

Desafíos en PLN

● Recursos y Datos Etiquetados

- La disponibilidad de grandes cantidades de datos etiquetados es crucial para entrenar modelos de PLN efectivos.
- Desafíos:
 - Escasez de Datos Etiquetados: En muchos dominios y lenguajes, los datos etiquetados son limitados.
 - Costos de Etiquetado: Etiquetar manualmente grandes conjuntos de datos es costoso y requiere mucho tiempo.
 - Calidad de las Etiquetas: La inconsistencia y errores en las etiquetas pueden afectar negativamente el rendimiento del modelo.
- Impacto en PLN: Sin suficientes datos de alta calidad, los modelos pueden no generalizar bien y tener un rendimiento pobre.
- Soluciones: Uso de técnicas de aprendizaje semi-supervisado, auto-supervisado y generación

automática de datos etiquetados.

Desafíos en PLN

- **Sesgo en los Modelos**

- Preferencias y prejuicios indeseados que los modelos pueden aprender de los datos de entrenamiento.
- Fuentes de Sesgo:
 - **Datos de Entrenamiento:** Los modelos pueden aprender y perpetuar sesgos presentes en los datos.
 - **Algoritmos:** Algunas arquitecturas y algoritmos pueden amplificar sesgos existentes.
 - **Interacciones de Usuarios:** Los sistemas interactivos pueden ser influenciados por el comportamiento sesgado de los usuarios.
- **Impacto:** Puede llevar a resultados injustos y discriminatorios, afectando la confiabilidad y equidad de los sistemas de PLN.
- **Soluciones:** Implementación de técnicas de mitigación de sesgo, auditorías y evaluaciones continuas de equidad, y uso de datos más representativos y diversos.

Bibliografía

- Steven Bird, Ewan Klein, and Edward Loper. 2009. Natural Language Processing with Python (1st ed.). O'Reilly Media, Inc.. ISBN: 0596516495 - <https://www.nltk.org/book/>
- Daniel Jurafsky and James H. Martin. 2023. Speech and Language Processing. 3rd Edition draft, Stanford University [\[link\]](#) •
- Christopher D. Manning and Hinrich Schütze. 1999. Foundations of Statistical Natural Language Processing, MIT. [\[link\]](#) •
- Graeme Hirst, Ed.. 2017. Neural Network Methods in Natural Language Processing-Morgan & Claypool Pub. [\[link\]](#) • Palash
- Goyal et. al. Deep Learning for Natural Language Processing. [\[link\]](#)
- Sarkar, Dipanjan. 2019. Text analytics with Python: a practitioner's guide to natural language processing. [\[link\]](#)



Fin de la clase